

# Máquinas de Vectores de Soporte

## Casos No Lineales

Luis Norberto Zúñiga Morales

20 de enero de 2022

## 1 Truco del Kernel

# MVS Caso No Lineal

Durante la construcción del clasificador se llegó a la ecuación

$$\sum_{i=1}^L \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i H_{ij} \alpha_j$$

donde se construyó la matriz

$$H_{ij} = y_i y_j \mathbf{x}_i \cdot \mathbf{x}_j$$

El producto punto de los vectores de entradas en la matriz anterior se puede representar como una función:

$$k(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j = \mathbf{x}_i^T \mathbf{x}_j \quad (1)$$

## Kernel


La función  $k(\mathbf{x}_i, \mathbf{x}_j)$  es un ejemplo de una familia de funciones llamadas **kernels**, las cuales se basan en el calculo de productos puntos de los vectores de entrada del conjunto de datos.

Los kernels son funciones  $x \mapsto \phi(x)$  que permiten mapear los datos a diferentes dimensiones **sin la necesidad de determinar la función  $\phi$**  que realiza el mapeo.

## Truco del Kernel

El **truco del kernel** permite atacar problemas que no son linealmente separables en el espacio en turno, y al realizar el mapeo por medio del kernel, es posible que en otro espacio sí sea separable.

# MVS Caso No Lineal



**Figura:** Ejemplo de un caso no linealmente separable y como el truco del kernel puede ser de utilidad.

# Truco del Kernel

Los kernels más comunes en la práctica son:

- Kernel Lineal:  $k(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$
- Kernel Polinomial:  $[\gamma(\mathbf{x}_i \cdot \mathbf{x}_j) + r]^d$
- Kernel Función de Base Radial:  $\exp(-\gamma \cdot \|\mathbf{x}_i - \mathbf{x}_j\|^2)$
- Kernel Sigmoide:  $\tanh(\mathbf{x}_i \cdot \mathbf{x}_j + r)$

donde  $\gamma > 0$  y  $r, d \in \mathbb{R}$ .

# Truco del Kernel

Expresado en la formulación del clasificador en la ecuación del primal:

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^L \xi_i \\ \text{sujeto a} \quad & y_i(\mathbf{w}^T \cdot \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i \quad \forall i \end{aligned} \tag{2}$$



# Truco del Kernel

Y su dual en la ecuación

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^L \alpha_i - \frac{1}{2} \alpha^T \mathbf{H}_k \alpha \\ \text{sujeto a} \quad & 0 \leq \alpha_i \leq C \quad \forall_i \\ & \sum_{i=1}^L \alpha_i y_i = 0 \end{aligned} \tag{3}$$

donde

$$\mathbf{H}_k = y_i y_j k(\mathbf{x}_i, \mathbf{x}_j). \tag{4}$$

# Truco del Kernel

1. Elegir de antemano cual es el kernel que se aplicará en la MVS y la función de mapeo  $\phi(\mathbf{x})$ . En práctica, el kernel de función de base radial funciona mejor.

# Truco del Kernel

1. Elegir de antemano cual es el kernel que se aplicará en la MVS y la función de mapeo  $\phi(\mathbf{x})$ . En práctica, el kernel de función de base radial funciona mejor.
2. Crear  $\mathbf{H}_k$ , donde  $H_{ij} = y_i y_j k(\mathbf{x}_i, \mathbf{x}_j)$ .

# Truco del Kernel

1. Elegir de antemano cual es el kernel que se aplicará en la MVS y la función de mapeo  $\phi(\mathbf{x})$ . En práctica, el kernel de función de base radial funciona mejor.
2. Crear  $\mathbf{H}_k$ , donde  $H_{ij} = y_i y_j k(\mathbf{x}_i, \mathbf{x}_j)$ .
3. Elegir el valor del parámetro  $C$ , el cual permitirá penalizar clasificaciones erróneas.

4. Encontrar las  $\alpha_j$  que maximicen

$$\sum_{i=1}^L \alpha_i - \frac{1}{2} \alpha^T \mathbf{H}_k \alpha$$

sujeto a las restricciones

$$0 \leq \alpha_i \leq C, \quad \sum_{i=1}^L \alpha_i y_i = 0.$$

mediante un programa para resolver problemas de optimización cuadrática.

4. Encontrar las  $\alpha_j$  que maximicen

$$\sum_{i=1}^L \alpha_i - \frac{1}{2} \alpha^T \mathbf{H}_k \alpha$$

sujeto a las restricciones

$$0 \leq \alpha_i \leq C, \quad \sum_{i=1}^L \alpha_i y_i = 0.$$

mediante un programa para resolver problemas de optimización cuadrática.

5. Calcular  $\mathbf{w} = \sum_{i=1}^L \alpha_i y_i \phi(\mathbf{x}_i)$ .

6. Determinar el conjunto de vectores de soporte  $S$  mediante la identificación de los índices  $i$  tales que  $0 \leq \alpha_i \leq C$ .

# Truco del Kernel

6. Determinar el conjunto de vectores de soporte  $S$  mediante la identificación de los índices  $i$  tales que  $0 \leq \alpha_i \leq C$ .
7. Calcular el valor de  $b$  mediante la ecuación

$$b = \frac{1}{N_S} \sum_{s \in S} (y_s - \sum_{k \in S} \alpha_k y_k k(\mathbf{x}_k, \mathbf{x}_s)).$$



# Truco del Kernel

6. Determinar el conjunto de vectores de soporte  $S$  mediante la identificación de los índices  $i$  tales que  $0 \leq \alpha_i \leq C$ .
7. Calcular el valor de  $b$  mediante la ecuación

$$b = \frac{1}{N_S} \sum_{s \in S} (y_s - \sum_{k \in S} \alpha_k y_k k(\mathbf{x}_k, \mathbf{x}_s)).$$

8. Cada elemento del conjunto de prueba  $\mathbf{x}_t$  se clasifica evaluando

$$y_t = \text{sgn}(\mathbf{w}^T \cdot \phi(\mathbf{x}_t) + b).$$